

Métodos de Monte Carlo

Camarena Perez, Victor Daniel

IMCA-UNI

09 de agosto del 2019

- 1 Introducción
- 2 El método de Monte Carlo
- 3 El método de Monte Carlo con Cadenas de Markov
- 4 Actualidad de los métodos de Monte Carlo

¿Qué es un algoritmo?

Un problema que enfrenta cualquiera que compile tal lista es definir qué se entiende por “**algoritmo**”. ¿Dónde se traza la línea entre un algoritmo y una técnica? Para un ejemplo simple,

¿poner una función racional en forma de fracción parcial es un algoritmo?

El algoritmo de Newton: Se pide hallar el cero de una función

$$x: f(x) = 0.$$


Fije $a < x_0 < b$, para cada $n \geq 0$ calcule

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}.$$

Lista según el número de localizadores en el índice del libro [The Princeton Companion to Applied Mathematics \(PCAM\)](#).

- 1 **Newton and quasi-Newton methods**
- 2 Matrix factorizations (LU, Cholesky, QR)
- 3 Singular value decomposition, QR and QZ algorithms
- 4 **Monte-Carlo methods**
- 5 Fast Fourier transform
- 6 Krylov subspace methods
- 7 JPEG
- 8 PageRank
- 9 Simplex algorithm
- 10 Kalman filter

Historia de los métodos de Monte Carlo



1946: John von Neumann, Stan Ulam y Nick Metropolis, todos en el Laboratorio Científico de Los Alamos, elaboran el algoritmo Metropolis, también conocido como el método Monte Carlo. El algoritmo Metropolis tiene como objetivo obtener soluciones aproximadas a problemas numéricos con muchos grados de libertad inmanejables y a problemas combinatorios de tamaño factorial, imitando un proceso aleatorio.

El **método congruencial mixto** empieza en una semilla x_0 y luego calcula de manera recursiva x_n , $n \geq 1$:

$$x_n = (ax_{n-1} + c) \text{ mód } m, \quad (1)$$

donde a y m son enteros positivos prefijados.

La cantidad x_n/m es llamada **número pseudoaleatorio** y se considera una aproximación de una variable aleatoria uniforme $]0, 1[$.

Generación de números pseudoaleatorios




Figura : El método congruencial mixto con parametros $a = 137$, $c = 0$, $m = 256$.

Método de Monte Carlo

¿Cómo funciona un algoritmo probabilístico?

Determinando si una moneda es justa:

Fije

$$p = Pr(\text{cara})$$

Sean los lanzamientos

$$X_1, X_2, \dots, X_N \sim Ber(p)$$

Calcule la fracción de éxitos

$$\frac{1}{N} \sum_{i=1}^N X_i \rightarrow p,$$

lo cual es la definición frecuentista de la probabilidad.

Sea

$$\theta = \int_0^1 f(x) dx$$

Esto se reescribe

$$\theta = \mathbb{E}(f(X))$$

donde $X \sim Unif([0, 1])$

Estimador del parámetro:

$$\hat{\theta} = \frac{1}{N} \sum_{i=1}^N f(X_i)$$

donde los $X_i \sim Unif([0, 1])$

Integral $\int_{-2}^2 e^x dx$ con un número de iteraciones $k = 1000$:

$$\int_{-2}^2 e^x dx = \mathbb{E} [e^U] \quad \text{donde} \quad U \sim \text{unif}(-2, 2).$$

Código en R.

```
% k <- 1000; s <- c(rep(0,each=k)); x <- 1:k
% s[1] = exp(runif(1,-2,2))
% for (i in 2:k)
%     s[i] <- s[i-1]+exp(runif(1,-2,2));
% plot(x,s/x)
%
```

Método de Monte Carlo

Integración por Monte Carlo




Figura : Integral $\int_{-2}^2 e^x dx$. Número de iteraciones $k = 1000$.

Algoritmo rechazo

- ① Use μ para seleccionar una muestra, x .
- ② Evalúe $\nu(x)$. Esto debe ser fácil, una vez que se tiene x .
- ③ Genere una variable aleatoria uniforme $u \sim U[0, 1)$.
 si $u \leq c \frac{\nu(x)}{\mu(x)}$
 entonces acepte x
 sino pruebe con otro x
Aquí se elige c de modo que $c \frac{\nu(x)}{\mu(x)} < 1$ para todo x .

La probabilidad de seleccionar y luego aceptar algún x es

$$c \frac{\nu(x)}{\mu(x)} \cdot \mu(x) = c\nu(x).$$




Figura : Simulación de una variable aleatoria normal por el método de Rechazo.
Número de iteraciones $n = 1000$.

Se desarrolló a principios del siglo XX como modelo de magnetización y fenómenos relacionados.

Cada configuración σ tiene una **energía** asociada

$$E(\sigma) = \sum_{i \sim j} J_{ij} \sigma_i \sigma_j - B \sum_k \sigma_k.$$

La media $\langle f \rangle$ de un observable f es

$$\langle f \rangle = \frac{1}{Z(T)} \sum_{\sigma} f(\sigma) \exp \left(-\frac{E(\sigma)}{\kappa T} \right).$$

La **función partición**

$$Z(T) = \sum_{\sigma} \exp \left(-\frac{E(\sigma)}{\kappa T} \right),$$

aquí T es la temperatura y κ es la constante de Boltzmann.

Un enfoque de muestreo por importancia natural podría ser seleccionar configuraciones según la distribución

$$\mu(\sigma) = \frac{1}{Z(T)} \exp\left(-\frac{E(\sigma)}{\kappa T}\right)$$

de modo que la media muestral, de M muestras,

$$\bar{f} = \frac{1}{M} \sum_{k=1}^M f(\sigma^k)$$

converja rápidamente a la media del observable, $\langle f \rangle$.

¡El problema es encontrar una forma de muestrear según μ !

Construcción de una **cadena de Markov simétrica aperiódica** que converja a la distribución límite μ . Las probabilidades de transición son tales que

$$\mu(\sigma) = \sum_{\xi} \mu(\xi) p_{\xi, \sigma}.$$

La suma es sobre todas las configuraciones ξ que difieren de σ por un spin, y


$$p_{\xi, \sigma} = \begin{cases} \frac{\mu(\sigma)}{\mu(\xi)} = \exp\left(-\frac{\Delta E}{kT}\right) & \text{si } \Delta E > 0 \\ 1 & \text{si } \Delta E < 0 \end{cases}$$

Dinámica de Metropolis:


- 1 Seleccione un sitio de manera uniforme
- 2 Acepte el cambio con probabilidad

$$\min \left\{ \exp\left(-\frac{\Delta E}{kT}\right), 1 \right\}$$


No magnetización: temperatura alta ($T = 4,0$)




i=500000



i=1000000




i=1500000




i=2000000


Magnetización: temperatura baja ($T = 0,4$)



i=500000



i=1000000



i=1500000



i=2000000

Hoy en día la metodología Monte Carlo se ha extendido en muchas direcciones en parte por la demanda que tiene. Así lo muestra la siguiente lista tentativa:

- Reversible Jump MCMC
- Optimal Proposal Distributions and Adaptive MCMC
- MCMC Using Hamiltonian Dynamics
- Spatial Point Processes
- Importance Sampling, Simulated Tempering, and Umbrella Sampling
- Likelihood-Free MCMC




Figura : El problema de la dimensionalidad.



The top 10 algorithms in applied mathematics.

<https://nickhigham.wordpress.com/2016/03/29/the-top-10-algorithms-in-applied-mathematics/>.

Accessed: 2018-09-10.



Barry A Cipra.

The best of the 20th century: Editors name top 10 algorithms.

SIAM news, 33(4):1–2, 2000.



Christian P Robert and George Casella.

Introducing monte carlo methods with r, volume 18.

Springer, 2010.



Ronald W Shonkwiler and Franklin Mendivil.

Explorations in Monte Carlo Methods.

Springer Science & Business Media, 2009.